

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



**BÁO CÁO BÀI TẬP LỚN MÔN THỊ GIÁC MÁY
DỰ ÁN VISION AGENT CALORIETRACK**

Nhóm 3

Giảng viên hướng dẫn:	PGS TS. Lê Thanh Hà
Môn học:	Thị giác máy
Lớp học phần:	INT3412E 2
Thành viên:	Nguyễn Văn Hòa – 23021556 Nguyễn Duy Phong – 23021656 Nguyễn Văn Vượng - 23021754

THÔNG TIN ĐÓNG GÓP THÀNH VIÊN

Thành viên	Nội dung thực hiện	Tỉ lệ
Nguyễn Văn Hòa	Phát triển AI - Agent, luồng dữ liệu, Backend, Database	40%
Nguyễn Duy Phong	Tìm hiểu, thử nghiệm AI - Agent, các mô hình sử dụng, UI/UX	30%
Nguyễn Văn Vượng	Tìm hiểu, thử nghiệm AI - Agent, các mô hình sử dụng, UI/UX	30%

Bảng: Phân chia công việc theo nhóm

Các thành viên trong nhóm đều tham gia xây dựng ý tưởng và đã cùng nhau phối hợp để giải quyết những vấn đề phát sinh trong quá trình triển khai, đảm bảo tiến độ và chất lượng của dự án.

MỤC LỤC

CHƯƠNG 1 TỔNG QUAN	4
1.1 Đặt vấn đề	4
1.2 Giải pháp đề xuất	5
CHƯƠNG 2 PHƯƠNG PHÁP LUẬN – VISION AGENT PIPELINE	7
2.1 Kiến trúc hệ thống	7
2.2 Chi tiết thông tin các mô hình sử dụng	9
2.3 Thuật toán tính toán Thể tích	11
2.4 Xử lý Video	13
2.5 Chuyển đổi sang Khối lượng	15
2.6 Xử lý bữa ăn nhiều món và Phân bổ khối lượng	16
2.7 Chuyển đổi sang Calo	18
CHƯƠNG 3 KẾT QUẢ VÀ BÁO CÁO PHẦN NHÓM LÀM, AI LÀM	20
3.1 Môi trường kiểm thử	20
3.2 Khả năng trực quan hóa kết quả	20
3.3 Đánh giá độ chính xác	21
3.4 Phần nội dung nhóm tự thực hiện	22
3.5 Phần nội dung AI thực hiện	23
CHƯƠNG 4 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	24
4.1 Kết luận	24
4.2 Hướng phát triển	24

CHƯƠNG 1

TỔNG QUAN

1.1 Đặt vấn đề

Trong bối cảnh xã hội hiện đại, việc theo dõi và kiểm soát lượng calo nạp vào cơ thể đóng vai trò quan trọng trong quản lý sức khỏe cá nhân, đặc biệt đối với các nhóm người có nhu cầu dinh dưỡng đặc thù như người ăn kiêng, người mắc bệnh chuyển hóa (tiểu đường, béo phì), vận động viên, hoặc người theo đuổi lối sống lành mạnh. Sự phát triển của các ứng dụng HealthTech trong những năm gần đây cho thấy nhu cầu ngày càng cao đối với các hệ thống hỗ trợ theo dõi dinh dưỡng một cách thuận tiện, chính xác và tự động.

Tuy nhiên, các phương pháp theo dõi lượng calo hiện nay vẫn tồn tại nhiều hạn chế đáng kể.

Thứ nhất, nhập liệu thủ công vẫn là phương pháp phổ biến nhất trong các ứng dụng đếm calo truyền thống. Người dùng phải tự lựa chọn món ăn, ước lượng khẩu phần và nhập dữ liệu bằng tay. Cách tiếp cận này không chỉ gây bất tiện và tốn thời gian, mà còn phụ thuộc lớn vào kinh nghiệm chủ quan của người dùng, dẫn đến sai số cao và làm giảm động lực sử dụng lâu dài.

Thứ hai, các phương pháp tự động dựa trên thị giác máy tính với ảnh 2D tuy đã có nhiều tiến bộ nhưng vẫn gặp giới hạn mang tính bản chất. Phần lớn các hệ thống hiện tại sử dụng các mô hình phân loại ảnh hoặc phát hiện đối tượng để xác định loại món ăn và vùng bao quanh (Bounding Box). Tuy nhiên, các phương pháp này chỉ khai thác thông tin trên mặt phẳng 2D, tức là diện tích chiếu của món ăn trên ảnh, mà không xét đến chiều sâu hoặc độ dày thực tế của vật thể.

Hạn chế này dẫn đến sai số nghiêm trọng trong việc ước lượng khối lượng và lượng calo. Ví dụ, một lát bánh mì mỏng và một ổ bánh mì dày có thể có diện tích 2D tương đương nhau trên ảnh chụp từ trên xuống, nhưng khối lượng và năng lượng nạp vào lại khác biệt hoàn toàn. Tương tự, một đĩa cơm đầy và một đĩa cơm vơi khó có thể được phân biệt chính xác nếu chỉ dựa vào diện tích vùng bao.

Ngoài ra, Bounding Box hình chữ nhật còn bao gồm nhiều vùng nền dư thừa như đĩa, bàn ăn hoặc các vật thể xung quanh, làm nhiễu quá trình tính toán diện tích và càng làm giảm độ chính xác của các phương pháp dựa trên ảnh 2D thuần túy.

Do đó, bài toán đặt ra là:

Làm thế nào để ước lượng lượng calo của món ăn từ ảnh một cách tự động, chính xác hơn, mà không cần đến các thiết bị phần cứng đắt tiền như camera stereo hay cảm biến LiDAR?

Bài toán này đòi hỏi một hệ thống có khả năng vượt qua giới hạn của không gian 2D, khai thác thêm thông tin về cấu trúc 3D và độ dày của món ăn, đồng thời vẫn đảm bảo tính khả thi, chi phí thấp và dễ triển khai trong các ứng dụng thực tế.

1.2 Giải pháp đề xuất

Để giải quyết những hạn chế của các phương pháp ước lượng calo truyền thống dựa trên ảnh 2D, dự án này đề xuất một hướng tiếp cận mới dựa trên khái niệm Vision Agent – một tác nhân thị giác thông minh có khả năng phân tích, suy luận và trích xuất thông tin đa chiều từ dữ liệu hình ảnh.

Thay vì chỉ dừng lại ở việc nhận diện loại món ăn hoặc đo diện tích bề mặt trên ảnh, Vision Agent được thiết kế nhằm tích hợp thông tin không gian ba chiều (3D) thông qua việc kết hợp các mô hình thị giác máy tính hiện đại và thuật toán suy luận dựa trên heuristic. Mục tiêu là ước lượng khối lượng và lượng calo của món ăn chính xác hơn, trong khi vẫn giữ được tính khả thi và chi phí thấp cho các ứng dụng thực tế.

Cụ thể, giải pháp được xây dựng dựa trên ba thành phần chính:

(1) Phân đoạn thực thể chính xác bằng Instance Segmentation

Hệ thống sử dụng mô hình YOLOv8-Segmentation để xác định chính xác biên dạng thực thể của từng món ăn trong ảnh thông qua các mặt nạ (segmentation masks). Không giống như phương pháp phát hiện đối tượng truyền thống chỉ trả về khung bao hình chữ nhật, Instance Segmentation cho phép loại bỏ hoàn toàn các vùng nền dư thừa như đĩa, bàn ăn hoặc các vật thể xung quanh. Nhờ đó, diện tích bề mặt được tính toán phản ánh sát hơn hình dạng thật của món ăn, tạo tiền đề quan trọng cho các bước suy luận tiếp theo.

(2) Khôi phục thông tin chiều sâu từ ảnh đơn (Monocular Depth Estimation)

Để vượt qua giới hạn không gian 2D, dự án tích hợp mô hình Depth Anything V2 nhằm ước lượng bản đồ độ sâu từ một ảnh RGB duy nhất. Mô hình này cho phép khôi phục thông tin tương đối về cấu trúc 3D của cảnh vật, trong đó các vùng có giá trị độ sâu cao hơn tương ứng với các phần nhô cao hoặc gần camera hơn. Việc kết hợp Depth Map với mặt nạ segmentation giúp hệ thống không chỉ biết món ăn nằm ở đâu, mà còn biết món ăn dày hay mỏng, từ đó phản ánh chính xác hơn thể tích thực tế.

(3) Thuật toán ước lượng thể tích dựa trên heuristic

Dựa trên kết quả từ hai bước trên, Vision Agent áp dụng một thuật toán heuristic để tính toán “Điểm Thể tích” (Volume Score) của từng món ăn. Thuật toán này kết hợp diện tích bề mặt (từ segmentation mask) và thông tin chiều sâu (từ depth map) nhằm xấp xỉ thể tích 3D của vật thể. Cách tiếp cận này cho phép phân biệt các trường hợp mà phương pháp 2D truyền thống không xử lý được, chẳng hạn như món ăn có diện tích nhỏ nhưng dày (bát com đầy) hoặc diện tích lớn nhưng mỏng (lát bánh mì).

Toàn bộ quy trình trên được tổ chức thành một pipeline ba giai đoạn, bao gồm: nhận diện và phân đoạn món ăn, ước lượng độ sâu, và suy luận thể tích – lượng calo. Pipeline này được triển khai dưới dạng hệ thống Client–Server theo kiến trúc Microservices, trong đó các mô hình thị giác nặng được xử lý ở phía server, còn logic nghiệp vụ và dữ liệu dinh dưỡng được quản lý ở backend riêng biệt. Cách tiếp cận này giúp hệ thống dễ mở rộng, linh hoạt và phù hợp với các kịch bản triển khai thực tế như ứng dụng di động hoặc web.

Thông qua việc tích hợp thông tin 3D và suy luận dựa trên thị giác, giải pháp đề xuất không nhằm thay thế hoàn toàn các thiết bị đo chuyên dụng, mà hướng tới một sự cân bằng giữa độ chính xác, chi phí và tính tiện dụng, qua đó mở ra tiềm năng ứng dụng rộng rãi trong các hệ thống theo dõi dinh dưỡng thông minh.

CHƯƠNG 2

PHƯƠNG PHÁP LUẬN - VISION AGENT PIPELINE

Hệ thống Vision Agent hoạt động theo quy trình 3 bước:

Nhận diện, xác định diện tích -> Tính toán độ sâu -> Tính toán Calo

2.1 Kiến trúc hệ thống

Hệ thống Vision Agent CalorieTrack được thiết kế theo mô hình Client–Server kết hợp kiến trúc Microservices, nhằm tách biệt rõ ràng giữa các tác vụ xử lý thị giác máy tính nặng và các tác vụ logic nghiệp vụ, quản lý dữ liệu. Cách tiếp cận này không chỉ giúp tối ưu hiệu năng mà còn nâng cao khả năng mở rộng và tái sử dụng của hệ thống.

2.1.1 Tổng quan kiến trúc

Ở mức tổng thể, hệ thống bao gồm ba thành phần chính:

- **Client:** Thiết bị đầu cuối của người dùng (web), chịu trách nhiệm thu nhận ảnh hoặc video món ăn và hiển thị kết quả.
- **Vision Service:** Dịch vụ xử lý thị giác máy tính, nơi triển khai các mô hình học sâu để phân tích hình ảnh.
- **Logic & Nutrition Service:** Dịch vụ xử lý logic suy luận và dữ liệu dinh dưỡng, chuyển đổi kết quả từ Vision Service thành thông tin calo cuối cùng.

Các thành phần này giao tiếp với nhau thông qua các API REST, đảm bảo tính độc lập và khả năng triển khai phân tán.

2.1.2 Vision Service

Vision Service được triển khai bằng Python, sử dụng framework FastAPI, và là thành phần trung tâm của hệ thống Vision Agent. Dịch vụ này đảm nhiệm toàn bộ các tác vụ tính toán chuyên sâu liên quan đến thị giác máy tính, bao gồm:

- Phân đoạn thực thể món ăn bằng mô hình YOLOv8-Segmentation.
- Ước lượng bản đồ độ sâu bằng mô hình Depth Anything V2.
- Tính toán các đặc trưng trung gian như diện tích vùng mask, giá trị độ sâu trung bình và điểm thể tích (Volume Score).

Vision Service được thiết kế để chạy trên môi trường có hỗ trợ GPU nhằm đảm bảo tốc độ suy luận nhanh, đặc biệt trong các kịch bản xử lý video hoặc nhiều món ăn trong cùng một ảnh. Đầu ra của dịch vụ này không phải là kết quả dinh dưỡng cuối cùng, mà là dữ liệu thô có cấu trúc, bao gồm segmentation mask, depth map và các chỉ số định lượng liên quan.

Việc tách Vision Service thành một microservice độc lập giúp hệ thống dễ dàng nâng cấp hoặc thay thế mô hình thị giác mà không ảnh hưởng đến các thành phần còn lại.

2.1.3 Logic & Nutrition Service

Logic & Nutrition Service được triển khai bằng Node.js với Express, đóng vai trò xử lý logic nghiệp vụ và suy luận dinh dưỡng. Dịch vụ này tiếp nhận dữ liệu đầu ra từ Vision Service và thực hiện các bước:

- Chuyển đổi điểm thể tích (Volume Score) sang khối lượng ước lượng (gram) thông qua các hệ số thực nghiệm.
- Tra cứu cơ sở dữ liệu dinh dưỡng để xác định lượng calo tương ứng với từng loại món ăn.
- Xử lý các trường hợp đặc biệt như ảnh chứa nhiều món ăn hoặc người dùng nhập tổng khối lượng thủ công.
- Chuẩn hóa và trả về kết quả cuối cùng cho Client.

Việc tách riêng phần logic dinh dưỡng giúp hệ thống linh hoạt trong việc cập nhật công thức tính toán, dữ liệu thực phẩm hoặc các quy tắc nghiệp vụ mà không cần can thiệp vào phần xử lý thị giác.

2.1.4 Luồng dữ liệu

Quy trình xử lý dữ liệu trong hệ thống diễn ra theo các bước sau:

1. Client gửi ảnh hoặc video món ăn lên hệ thống thông qua API.
2. Logic Service tiếp nhận yêu cầu và chuyển dữ liệu hình ảnh sang Vision Service.
3. Vision Service thực hiện pipeline thị giác, trả về dữ liệu thô (mask, depth, volume score).
4. Logic Service tiến hành suy luận dinh dưỡng và tính toán lượng calo.
5. Kết quả cuối cùng được gửi về Client để hiển thị cho người dùng.

Luồng xử lý này đảm bảo mỗi thành phần chỉ tập trung vào đúng chức năng của mình, giúp hệ thống đạt được sự cân bằng giữa hiệu năng, độ chính xác và khả năng mở rộng.

2.2 Chi tiết thông tin các mô hình sử dụng

Trong Vision Agent CalorieTrack, các mô hình học sâu đóng vai trò then chốt trong việc trích xuất thông tin không gian từ ảnh đầu vào. Thay vì sử dụng một mô hình duy nhất cho toàn bộ bài toán, hệ thống được thiết kế theo hướng kết hợp nhiều mô hình chuyên biệt, mỗi mô hình đảm nhiệm một nhiệm vụ cụ thể trong pipeline. Cách tiếp cận này giúp tận dụng tối đa thế mạnh của từng mô hình và nâng cao độ chính xác tổng thể của hệ thống.

Hai mô hình thị giác chính được sử dụng trong dự án bao gồm: mô hình phân đoạn thực thể YOLOv8-Segmentation và mô hình ước lượng độ sâu Depth Anything V2. Các mô hình này được lựa chọn dựa trên sự cân bằng giữa độ chính xác, tốc độ suy luận và khả năng triển khai trong môi trường thực tế.

2.2.1 Mô hình phân đoạn thực thể YOLOv8-Segmentation

a) Vai trò trong hệ thống

Mô hình YOLOv8-Segmentation được sử dụng ở giai đoạn đầu tiên của pipeline nhằm xác định vị trí, loại và biên dạng chính xác của từng món ăn trong ảnh. Kết quả của mô hình không chỉ cung cấp nhãn lớp mà còn trả về mặt nạ phân đoạn (segmentation mask) cho từng đối tượng, cho phép hệ thống trích xuất diện tích bề mặt của món ăn một cách chính xác.

Trong bối cảnh bài toán ước lượng calo, việc có được mask chính xác quan trọng hơn so với việc chỉ xác định bounding box, bởi diện tích bề mặt là một thành phần trực tiếp trong quá trình suy luận thể tích.

b) Kiến trúc và đặc điểm

YOLOv8-Segmentation là một biến thể mở rộng của kiến trúc YOLOv8, được thiết kế theo mô hình one-stage detector, trong đó việc phát hiện đối tượng và phân đoạn được thực hiện đồng thời trong một lần suy luận. Kiến trúc tổng thể bao gồm ba thành phần chính:

- **Backbone:** Trích xuất đặc trưng từ ảnh đầu vào bằng các khối convolution sâu, cho phép mô hình học được các đặc trưng không gian và ngữ nghĩa quan trọng.
- **Neck:** Kết hợp các đặc trưng đa tỉ lệ (multi-scale features) nhằm cải thiện khả năng phát hiện các đối tượng có kích thước khác nhau.
- **Head (Segmentation Head):** Sinh ra các dự đoán bao gồm nhãn lớp, độ tin cậy và mặt nạ phân đoạn cho từng đối tượng.

Trong dự án này, phiên bản YOLOv8 Nano Segmentation (yolov8n-seg) được lựa chọn do có số lượng tham số nhỏ, tốc độ suy luận nhanh và phù hợp với các hệ thống yêu cầu phản hồi gần thời gian thực.

c) Chiến lược lọc lớp (Class Filtering)

Mô hình YOLOv8n-seg được huấn luyện sẵn trên bộ dữ liệu COCO với 80 lớp đối tượng, trong đó chỉ một phần nhỏ liên quan đến thực phẩm. Để giảm nhiễu và tránh các dự đoán không cần thiết, hệ thống áp dụng kỹ thuật lọc lớp sau suy luận (post-inference class filtering).

Cụ thể, chỉ các đối tượng thuộc nhóm lớp thực phẩm (ví dụ: apple, pizza, sandwich, banana,...) mới được giữ lại để xử lý tiếp theo. Các đối tượng không liên quan như con người, dụng cụ ăn uống hoặc đồ nội thất bị loại bỏ hoàn toàn. Cách tiếp cận này giúp giảm sai số trong bước tính diện tích và cải thiện độ ổn định của hệ thống.

2.2.2 Mô hình ước lượng độ sâu Depth Anything V2

a) Vai trò trong hệ thống

Sau khi xác định được vùng phân đoạn của món ăn, hệ thống sử dụng mô hình Depth Anything V2 để ước lượng bản đồ độ sâu từ ảnh RGB đầu vào. Mục tiêu của bước này là khôi phục thông tin chiều sâu tương đối của cảnh, từ đó cho phép hệ thống suy luận về độ dày và cấu trúc 3D của món ăn.

Không giống như các hệ thống sử dụng camera stereo hoặc cảm biến chuyên dụng, Depth Anything V2 cho phép ước lượng độ sâu chỉ từ một ảnh đơn, giúp giảm chi phí phần cứng và tăng khả năng triển khai thực tế.

b) Đặc điểm và ưu điểm của mô hình

Depth Anything V2 là một mô hình ước lượng độ sâu đơn ảnh thuộc nhóm State-of-the-Art (SOTA) hiện nay. Mô hình được huấn luyện trên một tập dữ liệu quy mô rất lớn, kết hợp cả dữ liệu có gán nhãn và không gán nhãn, giúp cải thiện khả năng tổng quát hóa trên nhiều bối cảnh khác nhau.

Một số ưu điểm nổi bật của mô hình bao gồm:

- **Khả năng tái tạo chi tiết tốt:** Biên dạng vật thể rõ ràng, ít bị nhiễu ở vùng ranh giới giữa vật thể và nền.
- **Phân tách nền hiệu quả:** Giúp hạn chế ảnh hưởng của các vật thể không liên quan trong cảnh.

- **Tốc độ suy luận nhanh:** Đặc biệt với biến thể kích thước nhỏ (Small), phù hợp cho xử lý gần thời gian thực.

Đầu ra của mô hình là một bản đồ độ sâu tương đối (Relative Inverse Depth Map), trong đó giá trị pixel lớn hơn biểu thị các vùng gần camera hơn hoặc nhô cao hơn so với nền.

c) Kết hợp Depth Map với Segmentation Mask

Để đảm bảo thông tin độ sâu chỉ được khai thác cho vùng món ăn, hệ thống thực hiện phép masking giữa bản đồ độ sâu và mặt nạ phân đoạn thu được từ YOLOv8. Cụ thể, chỉ các pixel nằm trong vùng mask của món ăn mới được sử dụng trong các phép tính tiếp theo.

Việc kết hợp này giúp loại bỏ ảnh hưởng của nền và các vật thể xung quanh, đồng thời đảm bảo rằng các giá trị độ sâu được sử dụng phản ánh chính xác cấu trúc 3D của món ăn. Đây là bước then chốt giúp hệ thống chuyển từ phân tích 2D sang suy luận không gian 3D.

2.3 Thuật toán tính toán Thể tích

Mặc dù các mô hình thị giác máy tính hiện đại có khả năng nhận diện và ước lượng độ sâu của vật thể, bài toán ước lượng thể tích thực tế của món ăn từ ảnh 2D vẫn là một thách thức lớn, đặc biệt trong bối cảnh không có thông tin tuyệt đối về tỷ lệ không gian hay dữ liệu hiệu chuẩn camera. Do đó, thay vì cố gắng tái dựng hình học 3D chính xác, dự án này đề xuất một thuật toán heuristic nhằm ước lượng thể tích tương đối của món ăn thông qua một đại lượng trung gian được gọi là Điểm Thể tích.

Thuật toán này đóng vai trò là cầu nối giữa thông tin thị giác (segmentation và depth) và bước suy luận dinh dưỡng ở backend, đồng thời là đóng góp kỹ thuật cốt lõi của Vision Agent CalorieTrack.

2.3.1 Cơ sở ý tưởng

Trong không gian ba chiều, thể tích của một vật thể có thể được xấp xỉ bằng tích của diện tích đáy và chiều cao trung bình. Dựa trên trực giác này, thuật toán Volume Score tận dụng:

- **Diện tích bề mặt 2D** của món ăn (thu được từ segmentation mask).
- **Độ dày tương đối** của món ăn (thu được từ bản đồ độ sâu).

Mỗi pixel thuộc vùng segmentation có thể được xem như một phần tử diện tích vi mô, với giá trị độ sâu tương ứng phản ánh “chiều cao” tại vị trí đó.

Việc cộng dồn các giá trị độ sâu trên toàn bộ vùng mask cho phép xấp xỉ thể tích tổng thể của món ăn.

2.3.2 Công thức tính toán

Điểm Thể tích (Volume Score) của một món ăn được tính theo công thức:

$$\text{VolumeScore} = \frac{1}{K} \sum_{(x,y) \in \text{Mask}} \text{DepthMap}(x, y)$$

Trong đó:

- **Mask** là tập hợp tất cả các pixel nằm bên trong vùng phân đoạn của món ăn do mô hình YOLOv8-Segmentation trả về.
- **DepthMap(x, y)** là giá trị độ sâu tại vị trí pixel (x,y) do mô hình Depth Anything V2 ước lượng.
- **K** là hằng số chuẩn hóa nhằm đưa giá trị Volume Score về một miền giá trị ổn định và dễ xử lý trong các bước suy luận tiếp theo.

Trong quá trình thực nghiệm với ảnh đầu vào có kích thước 640×640 , hệ thống lựa chọn $K = 50.000$ dựa trên quan sát thực nghiệm để đảm bảo Volume Score không bị quá lớn hoặc quá nhỏ.

2.3.3 Diễn giải trực quan

Công thức trên có thể được hiểu như một phép xấp xỉ tích phân bề mặt, trong đó:

- Tổng số pixel trong Mask đại diện cho diện tích bề mặt của món ăn.
- Giá trị DepthMap tại mỗi pixel đóng vai trò như chiều cao cục bộ tại vị trí đó.

Do đó, thuật toán có khả năng phân biệt các trường hợp mà phương pháp dựa trên diện tích 2D truyền thống không xử lý được:

- Món ăn có diện tích lớn nhưng mỏng (ví dụ: lát bánh mì, miếng thịt nguội)
→ Tổng giá trị Depth thấp → Volume Score nhỏ.
- Món ăn có diện tích nhỏ nhưng dày hoặc vùn cao (ví dụ: bát com đầy, bát súp)
→ Tổng giá trị Depth cao → Volume Score lớn.

Nhờ vậy, Volume Score phản ánh tốt hơn cấu trúc không gian 3D của món ăn, dù chỉ dựa trên ảnh 2D đầu vào.

2.3.4 Ưu điểm và giới hạn của thuật toán

Ưu điểm:

- Không yêu cầu hiệu chuẩn camera hay thông tin tỷ lệ không gian tuyệt đối.
- Phù hợp với dữ liệu đầu vào đa dạng từ các thiết bị phổ thông (điện thoại, webcam).
- Dễ triển khai, chi phí tính toán thấp, phù hợp cho các hệ thống thời gian thực.

Giới hạn:

- Volume Score chỉ mang tính tương đối, không phải thể tích vật lý tuyệt đối.
- Độ chính xác phụ thuộc vào chất lượng của segmentation mask và depth map.
- Có thể bị ảnh hưởng bởi góc chụp không tối ưu hoặc hiện tượng che khuất.

Tuy nhiên, trong bối cảnh bài toán ước lượng calo cho người dùng phổ thông, các giới hạn này là chấp nhận được và được giảm thiểu thông qua các kỹ thuật xử lý tiếp theo.

2.4 Xử lý Video

Trong các kịch bản sử dụng thực tế, người dùng thường quay video món ăn thay vì chụp một ảnh tĩnh duy nhất. Tuy nhiên, dữ liệu video đặt ra những thách thức riêng cho bài toán ước lượng thể tích và lượng calo, do sự biến thiên liên tục theo thời gian của góc quay, ánh sáng và chuyển động camera. Nếu chỉ dựa vào kết quả của một khung hình đơn lẻ, hệ thống có thể đưa ra các ước lượng thiếu ổn định và dễ bị nhiễu.

Để giải quyết vấn đề này, Vision Agent CalorieTrack tích hợp cơ chế xử lý video với tính nhất quán theo thời gian, nhằm nâng cao độ ổn định và độ tin cậy của kết quả suy luận.

2.4.1 Các nguồn nhiễu trong dữ liệu video

Trong quá trình quay video, các yếu tố sau thường xuyên xuất hiện và gây ảnh hưởng đến kết quả suy luận:

- **Rung tay và chuyển động nhỏ của camera**, làm thay đổi nhẹ góc nhìn giữa các khung hình.
- **Thay đổi ánh sáng cục bộ**, đặc biệt trong môi trường trong nhà.
- **Hiện tượng che khuất tạm thời**, ví dụ như tay người hoặc dụng cụ ăn uống đi vào khung hình.
- **Biến động cục bộ của mô hình độ sâu**, do các mô hình monocular depth có thể cho kết quả khác nhau giữa các frame liên tiếp.

Những yếu tố này khiến giá trị Volume Score tính trên từng frame có thể dao động, dù món ăn thực tế không thay đổi.

2.4.2 Chiến lược Temporal Averaging

Để giảm thiểu ảnh hưởng của nhiễu theo thời gian, hệ thống áp dụng chiến lược Temporal Averaging, bao gồm các bước chính sau:

1. **Phân đoạn trên toàn bộ khung hình:**
Mô hình YOLOv8-Segmentation được chạy trên tất cả các frame của video nhằm đảm bảo việc nhận diện và hiển thị mask diễn ra mượt mà và nhất quán.
2. **Lấy mẫu định kỳ cho ước lượng độ sâu:**
Do mô hình Depth Anything V2 có chi phí tính toán cao hơn, hệ thống chỉ thực hiện ước lượng độ sâu trên một tập con các frame (ví dụ: mỗi 10–15 frame). Cách tiếp cận này giúp giảm tải tính toán mà vẫn đảm bảo độ đại diện của dữ liệu.
3. **Tính Volume Score cho từng mẫu:**
Với mỗi frame được lấy mẫu, thuật toán Volume Score (trình bày ở Mục 2.3) được áp dụng để tính điểm thể tích tương ứng.
4. **Trung bình hóa theo thời gian:**
Giá trị Volume Score cuối cùng được tính bằng trung bình cộng của các Volume Score trên toàn bộ tập frame mẫu.

2.4.3 Lợi ích của tiếp cận theo thời gian

Chiến lược Temporal Averaging mang lại nhiều lợi ích quan trọng cho hệ thống:

- **Giảm nhiễu ngẫu nhiên** do rung tay hoặc biến động ánh sáng.
- **Tăng độ ổn định của ước lượng thể tích**, đặc biệt trong các video quay ngắn.
- **Hạn chế ảnh hưởng của các frame kém chất lượng**, chẳng hạn như góc quay không tối ưu hoặc bị che khuất.
- **Cải thiện trải nghiệm người dùng**, khi kết quả không thay đổi thất thường giữa các thời điểm.

Nhờ đó, hệ thống có thể đưa ra một giá trị ước lượng đại diện tốt hơn cho món ăn thực tế, thay vì phụ thuộc vào một khung hình đơn lẻ.

2.5 Chuyển đổi sang Khối lượng

Sau khi tính toán được Điểm Thể tích cho từng món ăn thông qua pipeline thị giác, bước tiếp theo của Vision Agent là chuyển đổi đại lượng trung gian này sang khối lượng ước lượng (gram). Đây là bước then chốt nhằm kết nối thông tin thị giác với các bảng dữ liệu dinh dưỡng, vốn thường được xây dựng dựa trên đơn vị khối lượng.

Do Volume Score chỉ phản ánh thể tích tương đối, không mang ý nghĩa vật lý tuyệt đối, hệ thống không thể sử dụng trực tiếp các công thức vật lý truyền thống. Thay vào đó, dự án áp dụng một mô hình chuyển đổi thực nghiệm, dựa trên mối quan hệ gần tuyến tính giữa thể tích tương đối và khối lượng thực tế trong phạm vi các món ăn phổ biến.

2.5.1 Mô hình chuyển đổi tuyến tính

Khối lượng ước lượng của một món ăn được tính theo công thức:

$$\text{Mass (gram)} = \text{VolumeScore} \times \text{DensityFactor}$$

Trong đó:

- **VolumeScore** là điểm thể tích được tính theo thuật toán đã được trình bày ở trên
- **DensityFactor** là hệ số chuyển đổi thực nghiệm, phản ánh mật độ trung bình giữa thể tích tương đối và khối lượng thực tế của món ăn.

Thông qua quá trình thử nghiệm với nhiều loại món ăn khác nhau, nhóm quyết định lựa chọn giá trị mặc định $\text{DensityFactor} = 10$, đảm bảo kết quả khối lượng nằm trong khoảng hợp lý đối với khẩu phần ăn thông thường.

2.5.2 Cơ sở lựa chọn hệ số DensityFactor

Hệ số DensityFactor không nhằm đại diện chính xác cho mật độ vật lý của từng loại thực phẩm riêng biệt, mà đóng vai trò là một hệ số quy chiếu trung bình, giúp chuẩn hóa Volume Score về đơn vị gram.

Việc sử dụng một hệ số chung mang lại các lợi ích sau:

- Đơn giản hóa quá trình suy luận và triển khai hệ thống.

- Tránh phụ thuộc vào các đặc tính vật lý phức tạp hoặc dữ liệu hiệu chuẩn không sẵn có.
- Đảm bảo tính ổn định và nhất quán của kết quả trên nhiều loại món ăn khác nhau.

Trong các hướng phát triển nâng cao, hệ số DensityFactor có thể được điều chỉnh theo từng nhóm thực phẩm (ví dụ: rau, tinh bột, protein) để tăng độ chính xác.

2.5.3 Xử lý ngoại lệ và giới hạn giá trị

Trong thực tế, các mô hình thị giác có thể đưa ra các giá trị Volume Score bất thường do lỗi phân đoạn, góc chụp không phù hợp hoặc nhiễu trong bản đồ độ sâu. Để tránh việc các giá trị này gây ảnh hưởng tiêu cực đến trải nghiệm người dùng, hệ thống áp dụng cơ chế chặn giá trị đối với khối lượng ước lượng:

- **Khối lượng tối thiểu:** 20 gram
- **Khối lượng tối đa:** 1200 gram

Các giá trị nằm ngoài khoảng này sẽ được đưa về ngưỡng gần nhất. Cách tiếp cận này giúp loại bỏ các kết quả ngoại lai (outliers) và đảm bảo đầu ra của hệ thống luôn nằm trong miền giá trị hợp lý.

2.6 Xử lý bữa ăn nhiều món và Phân bổ khối lượng

Trong các tình huống sử dụng thực tế, một bữa ăn thường bao gồm nhiều món ăn khác nhau xuất hiện đồng thời trong cùng một ảnh hoặc video, ví dụ như một bữa ăn gồm pizza, trái cây và đồ uống. Việc xử lý chính xác các trường hợp đa món là yêu cầu quan trọng đối với một hệ thống theo dõi dinh dưỡng thông minh, bởi việc chia đều khối lượng hoặc lượng calo cho các món ăn sẽ dẫn đến sai lệch lớn và không phản ánh đúng thực tế.

Để giải quyết vấn đề này, Vision Agent CalorieTrack tích hợp cơ chế xử lý đa món và phân bổ khối lượng dựa trên tỷ trọng thể tích, tận dụng trực tiếp kết quả từ các bước phân tích thị giác trước đó.

2.6.1 Nhận diện và tách biệt các món ăn

Nhờ sử dụng mô hình Instance Segmentation, hệ thống có khả năng nhận diện và tách biệt từng món ăn như các thực thể độc lập, mỗi thực thể đi kèm với:

- Nhãn lớp (loại món ăn),
- Mặt nạ phân đoạn riêng biệt,

- Điểm thể tích (Volume Score) tương ứng.

Việc tách biệt này cho phép hệ thống xử lý từng món ăn một cách độc lập, ngay cả khi chúng nằm gần nhau hoặc chồng lấn một phần trong ảnh.

2.6.2 Trường hợp người dùng nhập tổng khối lượng

Trong một số kịch bản, người dùng có thể biết tổng khối lượng của bữa ăn (ví dụ: cân cả đĩa thức ăn) và nhập giá trị này vào hệ thống. Khi đó, thay vì sử dụng khối lượng ước lượng riêng lẻ cho từng món, hệ thống sẽ thực hiện phân bổ khối lượng tổng cho các món thành phần dựa trên tỷ trọng thể tích của chúng.

2.6.3 Thuật toán phân bổ theo tỷ trọng thể tích

Giả sử một bữa ăn gồm n món ăn, với các điểm thể tích lần lượt là $VolumeScore_1, VolumeScore_2, \dots, VolumeScore_N$. Khi người dùng nhập tổng khối lượng M_{total} , khối lượng phân bổ cho món ăn thứ i được tính theo công thức:

$$M_i = \frac{VolumeScore_i}{\sum_{j=1}^n VolumeScore_j} \times M_{total}$$

Cách phân bổ này đảm bảo rằng:

- Món ăn có thể tích tương đối lớn hơn sẽ nhận được phần khối lượng lớn hơn.
- Tổng khối lượng các món sau phân bổ đúng bằng tổng khối lượng người dùng cung cấp.
- Hạn chế sai lệch so với phương pháp chia đều khối lượng.

2.6.4 Ưu điểm của phương pháp phân bổ

Phương pháp phân bổ dựa trên Volume Score mang lại nhiều ưu điểm:

- **Phản ánh sát thực tế hơn** so với việc chia đều, đặc biệt khi các món ăn có kích thước và hình dạng khác nhau.
- **Tận dụng trực tiếp thông tin thị giác 3D**, không cần thêm dữ liệu đầu vào phức tạp.
- **Tăng độ tin cậy của kết quả calo**, đặc biệt trong các bữa ăn hỗn hợp.

Nhờ đó, hệ thống có thể xử lý hiệu quả các bữa ăn phức tạp, nâng cao trải nghiệm người dùng và tính ứng dụng của Vision Agent.

2.6.5 Liên kết với bước tính toán dinh dưỡng

Sau khi khối lượng của từng món ăn được xác định thông qua quá trình phân bổ, các giá trị này sẽ được sử dụng để tra cứu cơ sở dữ liệu dinh dưỡng và tính toán lượng calo tương ứng cho từng món. Điều này cho phép hệ thống không chỉ cung cấp tổng lượng calo của bữa ăn, mà còn đưa ra phân tích chi tiết theo từng món, hỗ trợ người dùng theo dõi chế độ ăn uống một cách toàn diện.

2.7 Chuyển đổi sang Calo

Sau khi khối lượng của từng món ăn đã được ước lượng thông qua các bước suy luận thị giác và phân bổ khối lượng, bước cuối cùng trong pipeline của Vision Agent là chuyển đổi khối lượng này sang calo. Đây là đầu ra trực tiếp mà người dùng quan tâm trong các ứng dụng theo dõi dinh dưỡng và quản lý sức khỏe.

Do dữ liệu dinh dưỡng của thực phẩm thường được thống kê dưới dạng lượng calo trên 100 gram, hệ thống thực hiện quá trình suy luận dựa trên việc tra cứu cơ sở dữ liệu dinh dưỡng kết hợp với khối lượng đã ước lượng.

2.7.1 Cơ sở dữ liệu dinh dưỡng

Hệ thống sử dụng một bảng dữ liệu dinh dưỡng chuẩn hóa, trong đó mỗi loại món ăn được gán với các thông tin cơ bản như:

- Tên món ăn / nhãn thực phẩm,
- Lượng kcal trên 100 gram,

Cơ sở dữ liệu này có thể được xây dựng từ các nguồn công khai hoặc các bảng thành phần dinh dưỡng phổ biến, và được lưu trữ tại database để dễ dàng cập nhật và mở rộng.

2.7.2 Công thức chuyển đổi sang calo

Lượng calo của một món ăn được tính theo công thức:

$$\text{Calories}_i = \frac{M_i}{100} \times \text{CaloriesPer100g}_i$$

Trong đó:

- M_i là khối lượng ước lượng (gram) của món ăn thứ i ,

- **CaloriesPer100gi** là lượng calo tương ứng với 100 gram của món ăn đó trong cơ sở dữ liệu dinh dưỡng.

Công thức này cho phép hệ thống dễ dàng mở rộng sang các chất dinh dưỡng khác bằng cách thay thế chỉ số calo tương ứng.

2.7.3 Tổng hợp lượng calo cho bữa ăn

Đối với các bữa ăn gồm nhiều món, lượng calo tổng được tính bằng cách cộng dồn lượng calo của từng món:

$$\text{Calories}_{\text{total}} = \sum_{i=1}^n \text{Calories}_i$$

Ngoài tổng lượng calo, hệ thống còn có khả năng cung cấp phân tích chi tiết theo từng món ăn, giúp người dùng hiểu rõ đóng góp calo của từng thành phần trong bữa ăn.

CHƯƠNG 3

KẾT QUẢ VÀ BÁO CÁO PHẦN NHÓM LÀM, AI LÀM

Chương này trình bày các kết quả thực nghiệm đạt được của hệ thống Vision Agent CalorieTrack, nhằm đánh giá khả năng hoạt động, tính trực quan và mức độ chính xác của phương pháp đề xuất trong các điều kiện sử dụng thực tế. Các thí nghiệm được thiết kế để kiểm chứng hiệu quả của việc tích hợp thông tin chiều sâu vào bài toán ước lượng khối lượng và lượng calo từ ảnh/video, so với các phương pháp truyền thống dựa trên ảnh 2D.

3.1 Môi trường kiểm thử

Các thí nghiệm được thực hiện trong môi trường có hỗ trợ tăng tốc phần cứng nhằm đảm bảo hệ thống hoạt động ổn định và phản ánh đúng năng lực triển khai thực tế.

Về phần cứng, Vision Service được triển khai trên một server Python có hỗ trợ GPU với CUDA enabled, giúp tăng tốc quá trình suy luận của mô hình Depth Anything V2 – thành phần có chi phí tính toán lớn nhất trong pipeline. Việc sử dụng GPU cho phép hệ thống xử lý ảnh và video với độ trễ thấp, phù hợp với các ứng dụng gần thời gian thực.

Về điều kiện thu thập dữ liệu, các ảnh và video kiểm thử được ghi nhận trong môi trường trong nhà với ánh sáng tương đối ổn định. Góc chụp được khuyến nghị là góc thẳng đứng (xấp xỉ 90 độ so với mặt phẳng bàn ăn), cùng với khoảng cách từ camera đến món ăn trong khoảng 30–50 cm. Đây là cấu hình phổ biến khi người dùng sử dụng điện thoại thông minh để chụp hoặc quay video món ăn, đồng thời giúp giảm méo hình và cải thiện chất lượng ước lượng độ sâu.

3.2 Khả năng trực quan hóa kết quả

Bên cạnh việc trả về các chỉ số định lượng, hệ thống Vision Agent CalorieTrack còn cung cấp các công cụ trực quan hóa nhằm giúp người dùng và nhà phát triển hiểu rõ hơn quá trình suy luận của hệ thống.

Một trong những tính năng nổi bật là Depth Vision Mode, cho phép người dùng chuyển đổi linh hoạt giữa:


- Chế độ xem ảnh gốc (RGB view)
- Chế độ xem bản đồ độ sâu (Depth Heatmap)

Trong chế độ Heatmap, bản đồ độ sâu được hiển thị bằng Magma colormap, trong đó:


- Các vùng của món ăn có độ dày lớn hoặc nằm gần camera hơn được hiển thị bằng các màu sáng (vàng/cam),
- Các vùng nền hoặc vật thể nằm xa camera hơn được hiển thị bằng các màu tối (tím/đen).

Sự phân bố màu sắc này cho phép quan sát trực quan cấu trúc không gian 3D của món ăn, qua đó minh họa rõ ràng khả năng “nhận thức chiều sâu” của Vision Agent. Kết quả trực quan cho thấy mô hình có khả năng phân biệt tương đối tốt giữa phần món ăn và nền, cũng như nhận diện được sự khác biệt về độ dày giữa các món ăn có hình dạng khác nhau.

3.3 Đánh giá độ chính xác



Hình 1: Quả cam



Hình 2: Quả chuối

Trong khuôn khổ dự án, việc đánh giá độ chính xác của hệ thống Vision Agent CalorieTrack được thực hiện chủ yếu theo hướng định tính kết hợp kiểm tra tính hợp lý của kết quả, do không có dữ liệu ground-truth tuyệt đối và không sử dụng các thiết bị đo chuyên dụng. Cách tiếp cận này phù hợp với mục tiêu của dự án là xây dựng một hệ thống ước lượng dinh dưỡng khả thi cho người dùng phổ thông.

Kết quả thực nghiệm cho thấy hệ thống hoạt động ổn định và cho độ chính xác khá cao với sai số nhỏ trong nhiều kịch bản thực tế. Như minh họa trong các hình ảnh kết quả, mô hình phân đoạn xác định đúng biên dạng của món ăn, đồng thời bản đồ độ sâu thể hiện rõ cấu trúc 3D và mức độ lỗi của vật thể so với nền. Điều này tạo tiền đề vững chắc cho các bước suy luận thể tích và khối lượng phía sau.

Đối với các ví dụ kiểm thử cụ thể như trái cây nguyên quả (cam, chuối), giá trị lượng calo được hệ thống ước lượng phù hợp với kích thước và hình dạng trực quan của món ăn, cũng như nằm gần các giá trị dinh dưỡng tham khảo thường gặp. Sai lệch quan sát được giữa kết quả dự đoán và giá trị thực tế ở mức nhỏ và không gây ảnh hưởng đáng kể đến mục đích sử dụng của hệ thống.

Các sai số còn tồn tại chủ yếu xuất phát từ yếu tố ngoại cảnh như chất lượng ảnh đầu vào, điều kiện ánh sáng, góc chụp hoặc tính tương đối của bản đồ độ sâu đơn ảnh. Tuy nhiên, trong hầu hết các trường hợp kiểm thử, hệ thống vẫn đưa ra kết quả nhất quán và hợp lý, cho thấy thuật toán suy luận và pipeline xử lý hoạt động hiệu quả.

Tổng thể, các kết quả đạt được chứng minh rằng Vision Agent CalorieTrack có khả năng ước lượng lượng calo với độ chính xác đáng tin cậy, sai số nhỏ và phù hợp với yêu cầu của các ứng dụng theo dõi dinh dưỡng không đòi hỏi độ chính xác tuyệt đối. Điều này khẳng định tính khả thi và giá trị thực tiễn của hệ thống trong các kịch bản sử dụng hàng ngày.

3.4 Phần nội dung nhóm tự thực hiện

Nhóm đã tự thực hiện hầu hết các nội dung của project Vision Agent CalorieTrack:

- Lên kế hoạch và xây dựng toàn bộ pipeline hệ thống WebApp.
- Tự code toàn bộ phần giao diện của hệ thống.
- Tự xây dựng hệ thống Backend và Database của project.
- Tự code toàn bộ phần API (cả cho model và phần backend) cần thiết cho hệ thống.
- Thử, đánh giá và tự quyết định sử dụng các mô hình AI để tích hợp vào hệ thống.
- Kiểm thử đơn giản để đảm bảo chạy tốt những phần chính liên quan đến pipeline hệ thống.

3.5 Phần nội dung AI thực hiện

Công cụ AI đã hỗ trợ nhóm những phần sau:

- Gợi ý những mô hình phù hợp cho bài toán.
- Code một số hàm hỗ trợ phổ biến như hiển thị ảnh, hiển thị video,...
- Fix một số lỗi khó trong quá trình lập trình như lỗi không tương thích phiên bản khi sử dụng nhiều thư viện liên quan đến nhau và một vài lỗi logic khác.

CHƯƠNG 4

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1 Kết luận

Trong khuôn khổ dự án, nhóm đã xây dựng thành công một Vision Agent hoàn chỉnh cho bài toán ước lượng khối lượng và lượng calo của món ăn từ ảnh và video. Hệ thống được thiết kế theo một pipeline xử lý ba giai đoạn, bao gồm: nhận diện và phân đoạn món ăn bằng YOLOv8-Segmentation, ước lượng độ sâu bằng mô hình Depth Anything V2, và suy luận thể tích – khối lượng thông qua các thuật toán heuristic.

Cách tiếp cận này đã vượt qua hạn chế cốt lõi của các ứng dụng đếm calo truyền thống, vốn chỉ dựa trên thông tin 2D và bỏ qua yếu tố độ dày của món ăn. Bằng việc tích hợp thông tin chiều sâu, Vision Agent CalorieTrack có khả năng phân biệt các món ăn có diện tích bề mặt tương tự nhưng khác biệt lớn về thể tích, từ đó đưa ra các ước lượng hợp lý hơn về khối lượng và lượng calo.

Kết quả thực nghiệm cho thấy hệ thống hoạt động ổn định trong các điều kiện chụp phổ biến bằng thiết bị di động, cung cấp kết quả trực quan và có sai số chấp nhận được trong bối cảnh không sử dụng các thiết bị đo chuyên dụng. Điều này chứng minh tính khả thi và tiềm năng ứng dụng của giải pháp trong các hệ thống theo dõi dinh dưỡng thông minh hướng tới người dùng phổ thông.

4.2 Hướng phát triển

Mặc dù đã đạt được những kết quả tích cực, hệ thống vẫn còn nhiều tiềm năng để cải thiện và mở rộng trong các nghiên cứu tiếp theo.

Thứ nhất, độ chính xác của việc ước lượng thể tích có thể được nâng cao đáng kể nếu hệ thống sử dụng một vật tham chiếu có kích thước thực đã biết, chẳng hạn như đồng xu hoặc thẻ chuẩn, xuất hiện trong cùng khung hình với món ăn. Việc này cho phép quy đổi từ độ sâu tương đối sang thang đo vật lý gần tuyệt đối, qua đó cải thiện độ chính xác của các bước suy luận sau.

Thứ hai, mô hình phân đoạn YOLOv8 có thể được fine-tune trên một bộ dữ liệu đa dạng hơn về các loại món ăn, đặc biệt là các món ăn đặc trưng trong bối cảnh địa phương. Điều này giúp cải thiện khả năng nhận diện và giảm nhiễu trong các tình huống phức tạp.

Cuối cùng, việc thu thập dữ liệu thực tế về khối lượng và thể tích của các món ăn sẽ cho phép xây dựng các hệ số chuyển đổi (DensityFactor) chính xác hơn, thậm chí theo từng nhóm hoặc từng loại thực phẩm. Hướng phát triển này mở ra khả năng chuyển từ các heuristic đơn giản sang các mô hình học máy nhẹ để suy luận khối lượng, từ đó nâng cao độ chính xác tổng thể của hệ thống.